



AIPF

AI Present Finder



Autorzy: Bartosz Gotowski • Dawid Chudzicki • Szymon Kowaliński • Marcin Dolatowski

Opiekun: dr inż. Marcin Jodłowiec, Katedra Informatyki Stosowanej, Wydział Informatyki i Telekomunikacji

Streszczenie

Wybór prezentu pochłania średnio 15 godzin rocznie, a ponad 50% upominków okazuje się nietrafionymi. Celem projektu jest stworzenie systemu rekomendacji, który skraca ten czas i zwiększa trafność. AI Present Finder łączy analizę publicznych profili społecznościowych (OSINT), konwersacyjny wywiad prowadzony przez LLM oraz agregację ofert z platform e-commerce (OLX, Allegro, eBay, Amazon). Kluczowym elementem jest reranking AI oceniający produkty z pełnym uzasadnieniem, co eliminuje ok. 40% szumu. System wdrożono produkcyjnie: średni czas do wyników wynosi 7,7 min, a w pilotażowej grupie testowej (11 opinii) użytkownicy zadeklarowali 80% satysfakcji i 64% trafności pierwszej rekomendacji. Wyniki pokazują, że połączenie social-data, wywiadu AI i rerankingu z uzasadnieniami znacząco podnosi jakość rekomendacji prezentowych.

1 WSTĘP

1.1 Problem i tło

Zakup prezentu dla bliskiej osoby jest zadaniem zaskakująco trudnym i kosztownym czasowo. Badania konsumenckie wskazują, że w sezonie świątecznym przeciętny kupujący spędza **około 15 godzin** na szukaniu prezentów [1], a **ponad 50%** osób co roku dostaje przynajmniej jeden nietrafiony upominek [2]. Przekłada się to na miliardy dolarów wydawanych na prezenty [8], które trafiają do zwrotu lub na dno szafy.

Równolegle ankiety dotyczące zakupów świątecznych (2025, $n = 322$) pokazują, że 37% respondentów nie wie, od czego zacząć wybór prezentu, 42% skarży się na brak dostępności pożądanых produktów, a 57% wskazuje wysokie ceny jako główną barierę [5]. Dodatkowo 23% uważa recenzje za niepomocne. Użytkownik gubi się w nadmiarze opcji, nie ufa ocenom innych i jednocześnie działa pod presją czasu oraz budżetu.

Z perspektywy rynku e-commerce te problemy oznaczają utracone przychody (porzucane koszyki, opóźnione zakupy, zwroty) oraz niską lojalność klientów. Z perspektywy użytkownika — stres, poczucie marnowania pieniędzy i brak satysfakcji z подарunku.

1.2 Cele projektu w kontekście biznesowym i technicznym

Celem projektu było zbudowanie asystenta zakupowego, który przejmie na siebie najbardziej frustrującą część procesu: wymyślenie pomysłu na prezent i odfiltrowanie dziesiątek nieistotnych ofert. Kluczowe założenia brzmiały:

- **Zmniejszyć czas potrzebny na znalezienie pomysłu** z kilkunastu godzin do kilku minut, dzięki temu, że system sam proponuje konkretne prezenty na podstawie profilu obdarowywanej osoby.
- **Zwiększyć trafność prezentów** poprzez wykorzystanie informacji o zainteresowaniach (z wywiadu i aktywności online) zamiast wyłącznie ogólnych filtrów typu kategoria/cena.
- **Ograniczyć szum ofertowy** — zamiast setek wyników z wyszukiwarki wyselekcjonować krótszą listę propozycji w oparciu o wewnętrzną ocenę przydatności.
- **Zebranie źródeł w jednym miejscu** tak, aby użytkownik nie musiał ręcznie przeskakiwać między wieloma sklepami.

Z biznesowego punktu widzenia projekt miał pokazać, że inteligentny asystent prezentowy może zwiększyć konwersję i średnią wartość koszyka: użytkownik szybciej dochodzi do decyzji, rzadziej rezygnuje z zakupu i chętniej wraca do narzędzia, które „zna” jego potrzeby. Z technicznego punktu widzenia celem było sprawdzenie, czy nowoczesne modele językowe potrafią nie tylko prowadzić rozmowę, ale też konsekwentnie przekładać zebrany kontekst na listę konkretnych produktów, które użytkownik realnie uzna za sensowne.

1.3 Oczekiwane korzyści i kryteria sukcesu

Na początku prac zdefiniowano mierzalne kryteria sukcesu:

- **Czas do pierwszych sensownych rekomendacji** krótszy niż 10 minut od startu rozmowy.
- **Subiektywna trafność** na poziomie co najmniej 60% — użytkownik powinien uznać większość propozycji za realne opcje, a nie przypadkowe wyniki wyszukiwania.
- **Weryfikowalność decyzji** — system powinien generować wewnętrzne uzasadnienie dla każdej rekomendacji, co pozwala na audyt jakości i eliminację halucynacji.

2 PRACE ZWIĄZANE Z TEMATEM

2.1 Analiza rozwiązań rynkowych

Rynek cyfrowego wsparcia w obdarowywaniu przeszedł ewolucję od statycznych list życzeń (np. GiftList) do interaktywnych asystentów AI. Obecne rozwiązania można podzielić na dwa główne segmenty:

- **Rozwiązania B2B (Corporate Gifting):** Liderzy tacy jak *Giftpack.ai* [3] czy *Snappy* [9] oferują zaawansowaną personalizację opartą na analizie śladu cyfrowego (OSINT) i danych firmowych. Osiągają wysoką satysfakcję (deklarowane 98% [3]), jednak są to narzędzia drogie, dostępne w modelu subskrypcyjnym dla działów HR i sprzedaży, niedostępne dla klienta indywidualnego.
- **Rozwiązania B2C (Consumer Chatbots):** Aplikacje takie jak *DreamGift* czy *Giftruly* to zazwyczaj proste nakładki na modele językowe (LLM). Choć są łatwo dostępne, cierpią na brak kontekstu — opierają się wyłącznie na tym, co użytkownik wpisze w oknie czatu. Często generują generyczne pomysły lub „halucynują” nieistniejące produkty, co prowadzi do niskiego zaufania użytkowników.

Istnieje wyraźna luka rynkowa: brak narzędzia konsumenckiego, które łączyłoby głęboką analizę danych (jak w B2B) z prostotą obsługi, jednocześnie oferując produkty z lokalnego rynku, a nie tylko z globalnych katalogów typu Amazon.

2.2 Pozycjonowanie i wyróżniki AI Present Finder

Projekt AI Present Finder (AIPF) pozycjonuje się w kategorii *Agentic Commerce* [7] — systemów, które nie tylko doradzają, ale aktywnie wyszukują i weryfikują oferty. Główne wyróżniki względem konkurencji to:

1. **Demokratyzacja OSINT:** Przeniesienie technologii analizy profili społecznościowych (Instagram, TikTok) z sektora korporacyjnego do konsumenckiego. Pozwala to rozwiązać problem „zimnego startu” — system wie o zainteresowaniach odbiorcy, zanim użytkownik o nich napisze.
2. **Reranking z wewnętrzną weryfikacją (XAI):** W przeciwieństwie do „czarnych skrzynek” konkurencji, AIPF każdą rekomendację weryfikuje poprzez generowanie wewnętrznego uzasadnienia (np. „Wybrano ten aparat, ponieważ na profilu odbiorcy widać fascynację fotografią analogową”). Pozwala to na skuteczną eliminację nietrafionych ofert przed ich wyświetleniem.
3. **Lokalna agregacja (Local Moat):** Integracja z platformami takimi jak OLX i Allegro daje dostęp do przedmiotów unikatowych, vintage i z drugiej ręki. Jest to przewaga nad globalnymi graczami, którzy często ograniczają się do nowych produktów z Amazon.

Tabela 1: Komponenty architektury mikroserwisowej

Komponent	Odpowiedzialność
REST API	Punkt wejścia HTTP, streaming wyników przez SSE
Stalking	Analiza profili społecznościowych (BrightData + OpenAI)
Chat	Prowadzenie wywiadu AI (Google Gemini)
Gift Ideas	Generowanie pomysłów na prezenty
Fetch (×4)	Równoległe pobieranie ofert z platform e-commerce
Reranking	Ocena i filtracja produktów przez LLM

2.3 Założenia projektowe i wyzwania realizacyjne

Realizacja tak zdefiniowanego systemu wymagała przyjęcia specyficznych założeń architektonicznych i zmierzenia się z barierami technologicznymi.

Architektura i technologie: System oparto na architekturze mikroserwisowej, gdzie każdy komponent odpowiada za wydzieloną funkcjonalność (Tabela 1).

Komunikacja między komponentami odbywa się asynchronicznie przez broker RabbitMQ (wzorzec CQRS [6]), co pozwala na niezależne skalowanie modułów i obsługę długotrwałych procesów (scraping, wnioskowanie LLM).

Kluczowe wyzwania i ograniczenia:

- **Latencja a User Experience:** Głęboka analiza (OSINT + pobranie setek ofert + reranking LLM) trwa średnio 7,7 minuty. Aby utrzymać zaangażowanie użytkownika, zastosowano streaming SSE (Server-Sent Events), który prezentuje postępy i częściowe wyniki w czasie rzeczywistym.
- **Dostęp do danych:** Platformy e-commerce i społecznościowe stosują agresywne limity (rate-limiting). Wymusiło to użycie sieci proxy (BrightData) oraz implementację mechanizmów *backoff* i rotacji instancji pobierających.
- **Jakość danych wejściowych:** Oferty z rynku wtórnego (OLX) często mają ubogie opisy. Zastosowanie modeli wizyjnych (multimodal LLM) do analizy zdjęć produktów byłoby idealne, ale ze względów budżetowych w MVP skupiono się na analizie tekstowej, co czasem prowadzi do błędów w dopasowaniu.

3 WYNIKI WDROŻENIA I EWALUACJA

System został wdrożony w środowisku produkcyjnym i poddany testom z udziałem rzeczywistych użytkowników. Poniższa sekcja prezentuje wyniki w trzech kluczowych wymiarach: efektywności biznesowej (oszczędność czasu), jakości sztucznej inteligencji (trafność rekomendacji) oraz stabilności technicznej rozwiązania.

Dane zebrano w okresie pilotażowym (listopad 2025), obejmującym 36 pełnych sesji zakupowych, podczas których przetworzono ponad 1300 ofert z rynku e-commerce.

3.1 Efektywność biznesowa: Czas i Skala

Głównym celem projektu była redukcja czasu potrzebnego na znalezienie prezentu. W tradycyjnym modelu proces ten zajmuje konsumentom średnio 15 godzin rocznie. AI Present Finder zredukował ten czas do średnio **7 minut i 44 sekund** (464 s) na jedną sesję.

W tym czasie „cyfrowy asystent” wykonuje pracę niemożliwą dla człowieka w tak krótkim oknie czasowym:

- Przeprowadza pogłębiony wywiad (średnio 12 pytań doprecyzujących).
- Analizuje setki ofert z wielu źródeł (średnio 116 produktów na start).
- Dokonuje semantycznej oceny każdego produktu, odrzucając te nietrafione.

Tabela 2: Kluczowe wskaźniki efektywności (KPI) wdrożenia pilotażowego

Wskaźnik	Wynik
Średni czas realizacji usługi	7 min 44 s
Redukcja szumu informacyjnego	~40% ofert odrzucanych przez AI
Trafność Top-1 (First Hit Accuracy)	64%

3.2 Inteligencja systemu: Mechanizm Rerankingu

Największą wartością dodaną systemu nie jest samo wyszukiwanie, lecz **inteligentna filtracja**. Wdrożony moduł Rerankingu (oparty na modelu Gemini 2.5 [4]) działa jak doradca, który chroni użytkownika przed nieadekwatnymi ofertami.

Analiza logów wykazała, że system skutecznie eliminuje sytuacje, gdzie proste dopasowanie słów kluczowych prowadzi do skrajnie nieprawidłowych wyników.

Tabela 3: Dowód działania inteligencji systemu (Przykłady decyzji AI)

Produkt (znaleziony po słowach kluczowych)	Ocena AI	Decyzja i Uzasadnienie
Nintendo Switch OLED Pokemon Edition	10/10	„Idealne dopasowanie dla fana gier i serii Pokemon.”
Klawiatura Razer BlackWidow	9/10	„Sprzęt premium zgodny z profilem technologicznym.”
Zestaw noży kuchennych	5/10	„Akceptowalne, ale poboczne wobec głównych zainteresowań.”
Jeep Wrangler Sahara (Samochód)	1/10	„ODRZUCONO. Produkt to samochód, brak związku z prezentem.”

Jak pokazuje Tabela 3, system potrafi odróżnić gadżet motoryzacyjny od prawdziwego samochodu, mimo że oba pasują do słowa kluczowego „motoryzacja”. Dzięki temu użytkownik otrzymuje listę skróconą ze 116 do ok. 70 pozycji, ale o znacznie wyższej gęstości wartościowych ofert.

3.3 Odbiór użytkowników i User Experience

W badaniu jakościowym (feedback opisowy + oceny gwiazdkowe) system uzyskał średnią ocenę **3.5 / 5.0**. Choć wskazuje to na obszary do poprawy, szczegółowa analiza opinii ujawnia wysoki potencjał rozwiązania:

- Wysoka trafność (Precision):** Aż 64% użytkowników uznało już pierwszą rekomendację za „trafioną w sedno”. Opinie takie jak „Dobry pomysł na prezent, trafiony bardzo dobrze” potwierdzają skuteczność profilowania.
- Problem „posiadania”:** Głównym zarzutem (obniżającym oceny) było polecanie rzeczy, które obdarowywany już ma (np. „Osoba posiada już keyboard”). Jest to problem braku „pamięci negatywnej” w MVP, a nie błędu wnioskowania.
- Bias źródłowy:** Dominacja ofert z OLX (99%) była krytykowana przez użytkowników oczekujących nowych produktów z gwarancją.

3.4 Stabilność techniczna

Mimo złożoności procesu (równoległe scrapowanie 4 platform, streaming SSE, wnioskowanie LLM), system wykazał się 100% dostępnością (uptime) w okresie testowym. Kolejki RabbitMQ były opróżniane na bieżąco (o message lag), a zużycie pamięci RAM dla całego klastra 9 mikroserwisów nie przekroczyło 800 MB. Potwierdza to, że architektura jest wysoce zoptymalizowana i gotowa do skalowania przy minimalnych kosztach chmurowych.

←

Nowy prezent

4/30

Dziewczyna

W jakim przedziale wiekowym jest?

18-25 lat

Co robi w wolnym czasie?

Czytanie

Sport

Filmy/Seriale

Podróże

Programuje

Wyślij

Anuluj

Szukaj

Zapisane

Historia

Profil

←

Rekomendacje prezentów

Szukaj...

Sklepy

Zakres cen

Kategoria

Wyświetlanie 97 prezentów

olx

29.00 PLN

Termos GOPPUS butelka do picia ...

Kup teraz

olx

20.00 PLN

Stalowa butelka na wodę - możn...

Kup teraz

olx

olx

Szukaj

Zapisane

Historia

Profil

(a) Wywiad AI budujący profil psychometryczny

(b) Wyniki z transparentnym uzasadnieniem

Rysunek 1: Interfejs użytkownika w akcji: (a) wywiad AI budujący profil, (b) lista rekomendacji wyselekcjonowana przez system.

4 WNIOSKI

Wdrożenie AI Present Finder pozwoliło zweryfikować potencjał tzw. *Agentic Commerce* w praktyce. Najważniejszym sukcesem projektu jest udowodnienie, że **autonomiczny agent AI potrafi skutecznie przejąć proces decyzyjny człowieka** - od analizy potrzeb, przez przeszukanie rynku, aż po selekcję ofert.

Kluczowe wnioski z wdrożenia:

- **Wartość biznesowa:** System realnie rozwiązuje problem „paraliżu decyzyjnego”. Skrócenie procesu z godzin do minut przy zachowaniu 64% trafności pierwszej rekomendacji to wynik, który w warunkach komercyjnych przekłada się bezpośrednio na konwersję sprzedażową.
- **Jakość selekcji dzięki XAI:** Mechanizm wewnętrznych uzasadnień pozwolił na skuteczną eliminację „halucynacji” i ofert nietrafionych, co bezpośrednio przełożyło się na wysoką trafność rekomendacji (64% Top-1) bez konieczności angażowania użytkownika w filtrowanie.
- **Stabilność architektury:** Rozwiązanie oparte na asynchronicznych mikroserwisach wykazało 100% niezawodności, potwierdzając, że skomplikowane procesy AI można obsługiwać w sposób skalowalny i tani w utrzymaniu.

5 KIERUNKI ROZWOJU

Zdefiniowano cztery strategiczne ścieżki rozwoju systemu:

1. **Optymalizacja czasu reakcji** — redukcja czasu oczekiwania poniżej 2 minut poprzez pipeline streaming i równoległe przetwarzanie.
2. **Wyszukiwanie wektorowe** — rekomendowanie produktów semantycznie zbliżonych dzięki embeddingom, nawet bez dopasowania słów kluczowych.
3. **Wywiad adaptacyjny** — mniej, ale bardziej precyzyjnych pytań, dynamicznie dostosowanych do kontekstu rozmowy.
4. **System rekomendacji oparty na feedbacku** — uczenie się z ocen użytkowników (wzorem platform streamingowych).

6 POTENCJALNY MODEL BIZNESOWY

Niskie koszty operacyjne systemu otwierają możliwość komercjalizacji w przyszłości. W przypadku podjęcia decyzji o monetyzacji, rozważane byłyby trzy strumienie przychodów:

1. **Marketing afiliacyjny** — prowizje od przekierowań do sklepów partnerskich (Allegro, Amazon, eBay). Darmowe dla użytkownika, motywowałoby system do trafnych rekomendacji.
2. **Promowane produkty** — wyróżnianie ofert sponsorowanych w wynikach (oznaczonych jako „Promowane”).
3. **Subskrypcja Pro** — więcej rekomendacji, dostęp do dodatkowych platform, priorytetowe przetwarzanie, historia wyszukiwań i powiadomienia o promocjach.

Model freemium (darmowa wersja podstawowa + płatne rozszerzenia) zapewniłby niski próg wejścia przy jednoczesnej możliwości skalowania przychodów.

LITERATURA

- [1] Consumer Reports. Holiday shopping survey: Time spent and gift returns. <https://www.consumerreports.org/cro/news/2010/11/americans-spend-42-hours-each-on-holiday-shopping-and-partying/index.htm>, 2010. Statystyki dotyczące czasu poświęconego na zakupy prezentowe.
- [2] Finder.com. Unwanted gifts statistics: How much do we waste? <https://www.finder.com/uk/unwanted-gifts>, 2024. Dane o nietrafionych prezentach i ich wartości.
- [3] Giftpack Inc. Ai-powered corporate gifting & social recognition — 98% satisfaction rate. <https://giftpack.ai/>, 2025. Dostęp: 05.12.2025.
- [4] Google DeepMind Team. Gemini: A family of highly capable multimodal models. Technical report, Google DeepMind, 2025. Wersja modelu: 2.5 Pro. Dostęp: 05.12.2025.
- [5] Kinetic319. 7 holiday shopping frustrations and how retailers can solve them. <https://kinetic319.com/blogs/news/7-holiday-shopping-frustrations>, 2025. Badanie $n = 322$ respondentów. Dostęp: 01.12.2025.
- [6] Martin Fowler. CQRS — command query responsibility segregation. <https://martinfowler.com/bliki/CQRS.html>, 2011. Dostęp: 30.11.2025.
- [7] McKinsey & Company. The agentic commerce opportunity: How ai agents are ushering in a new era for consumers. *McKinsey QuantumBlack Insights*, October 2025. Dostęp: 05.12.2025.
- [8] National Retail Federation. Nrf expects holiday sales to surpass \$1 trillion for the first time. <https://nrf.com/media-center/press-releases>, 2025. Dostęp: 05.12.2025.
- [9] Snappy Gifts. Holiday gifting 2025: Gifts lift brand perception and employee job satisfaction. <https://www.snappy.com/press-releases>, 2025. Dostęp: 05.12.2025.